

1. GİRİŞ

Bu çalışmada Word2Vec algoritması kullanılarak metinler arası anlamsal benzerlik analizi gerçekleştirilmiştir. Amaç, farklı Word2Vec model yapılandırmalarının (CBOW ve Skip-gram), farklı pencere boyutlarının (window size) ve vektör boyutlarının (embedding dimension) metin benzerliği üzerindeki etkilerini incelemektir.

Bu kapsamda lemmatized ve stemmed olmak üzere iki farklı ön işlenmiş veri seti kullanılmış ve toplamda 16 farklı model eğitilmiştir.

2. YÖNTEM

2.1 Veri Setleri

Çalışmada iki farklı veri seti kullanılmıştır:

- Lemmatized Sentences
- Stemmed Sentences

Bu veri setleri, metinlerin kök ve anlamlı formlarına indirgenmiş halidir.

2.2 Word2Vec Model Eğitimi

Toplamda 16 farklı Word2Vec modeli eğitilmiştir.

Kullanılan parametreler:

- Model türü: CBOW ve Skip-gram
- Window size: 2 ve 4
- Vector size: 100 ve 300

Bu kombinasyonlar ile her veri seti için 8 model eğitilmiş ve toplamda 16 model elde edilmiştir.

2.3 Metin Temsili

Her metin, içindeki kelimelerin Word2Vec vektörlerinin ortalaması alınarak temsil edilmiştir. Eğer bir metin içinde modele ait kelime bulunmazsa, sıfır vektörü atanmıştır.

2.4 Benzerlik Hesaplama

Metinler arası benzerlik cosine similarity yöntemi ile hesaplanmıştır. Her model için bir giriş metni seçilmiş ve veri seti içerisindeki tüm metinlerle karşılaştırılarak en benzer 5 metin elde edilmiştir.

2.5 Model Karşılaştırma Yöntemi

Modeller aşağıdaki yöntemlerle karşılaştırılmıştır:

- Cosine similarity değerleri
- Anlamsal değerlendirme (manuel 1–5 puanlama)

- Jaccard similarity ile sıralama tutarlılığı

3. SONUÇLAR VE DEĞERLENDİRME

3.1 Cosine Similarity Sonuçları


Her model için giriş metnine en benzer 5 metin elde edilmiştir.

Örnek format:

- Model A → [0.85, 0.79, 0.72, 0.68, 0.65]
- Model B → [0.62, 0.58, 0.55, 0.51, 0.44]

.2 Jaccard Similarity Analizi

Modellerin ürettiği ilk 5 sonuç arasındaki örtüşme Jaccard similarity yöntemi ile ölçülmüştür. Bu yöntem, modellerin sıralama tutarlılığını değerlendirmek için kullanılmıştır.



3.3 Anlamsal Değerlendirme

Modeller tarafından önerilen sonuçlar 1–5 arası manuel olarak puanlanmıştır:

- 1: Çok alakasız
- 2: Zayıf ilişki
- 3: Orta düzey benzerlik
- 4: Güçlü benzerlik
- 5: Çok yüksek benzerlik

Genel olarak Skip-gram modellerinin daha anlamlı sonuçlar ürettiği gözlemlenmiştir.

3.4 Model Karşılaştırması

Yapılan analizler sonucunda:

- CBOW modelleri daha genel ve stabil sonuçlar üretmiştir.
- Skip-gram modelleri daha bağlamsal ve anlamlı sonuçlar vermiştir.
- Window size 4 olan modeller daha geniş bağlam yakalayarak daha başarılı olmuştur.
- 300 boyutlu vektörler 100 boyutlu modellere göre daha zengin temsil sağlamıştır.

Genel olarak en başarılı model kombinasyonu Skip-gram + window=4 + vector size=300 olarak gözlemlenmiştir.

4. SONUÇ VE ÖNERİLER

Word2Vec tabanlı modellerin metin benzerliği problemlerinde etkili olduğu görülmüştür. Model parametreleri performans üzerinde doğrudan etkili olmaktadır.

Gelecekte daha büyük veri setleri ve daha gelişmiş modeller (örneğin BERT gibi transformer tabanlı modeller) ile karşılaştırmalı çalışmalar yapılabilir.

